**Министерство образования и науки Российской Федерации**
**Федеральное государственное бюджетное образовательное учреждение**
**высшего профессионального образования**
**«Московский государственный технический университет имени Н.Э. Баумана»**
**(МГТУ им. Н.Э. Баумана)**

| | |
|---|---|
| **ФАКУЛЬТЕТ** | **«Информатики и систем управления»** |
| **КАФЕДРА** | ИУ5 |


Дисциплина «Технологии мультимедиа»

# ОТЧЕТ
# ПО ЛАБОРАТОРНОЙ РАБОТЕ №2
# «Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных.»


| | | |
|---|---|---|
| Студент | Группы ИУ5-62Б | Гришин Илья |
| Преподаватель | | Гапанюк Ю.Е. |

**Цель лабораторной работы:** изучение способов предварительной обработки данных для дальнейшего формирования моделей.

**Задание:**

1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:
    - обработку пропусков в данных;
    - кодирование категориальных признаков;
    - масштабирование данных.

**Использованный набор данных:**

https://www.kaggle.com/jesneuman/pc-games

# Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных.

In [1]:

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

## Загрузка и первичный анализ данных

Используем датасет [PC Games 2020] игр **Steam** с добавлением данных **RAWG API**

In [2]:

```
# Будем использовать только обучающую выборку
data = pd.read_csv('games.csv', sep=",")
```

In [3]:

```
# размер набора данных
data.shape
```

Out[3]:

```
(30250, 27)
```

In [4]:

```
# типы колонок
data.dtypes
```

Out[4]:

```
Unnamed: 0            int64
id                    int64
Name                 object
RawgID              float64
SteamURL             object
Metacritic          float64
Genres               object
Indie               float64
Presence            float64
Platform             object
Graphics             object
Storage              object
Memory               object
RatingsBreakdown     object
ReleaseDate          object
Soundtrack          float64
Franchise            object
OriginalCost         object
DiscountedCost       object
Players              object
Controller          float64
Languages            object
ESRB                 object
Achievements        float64
Publisher           float64
Description          object
Tags                 object
dtype: object
```

In [5]:

```
# проверим есть ли пропущенные значения
data.isnull().sum()
```

Out[5]:

```
Unnamed: 0              0
id                      0
Name                   94
RawgID                 94
SteamURL               55
Metacritic          26894
Genres               2968
Indie                 205
Presence               94
Platform              127
Graphics             4320
Storage              2759
Memory               1934
RatingsBreakdown    15206
ReleaseDate          3226
Soundtrack            205
Franchise           25163
OriginalCost          746
DiscountedCost      29523
Players             17916
Controller            274
Languages             223
ESRB                25503
Achievements           94
Publisher           30250
Description           219
Tags                  205
dtype: int64
```

In [6]:

```
# Первые 5 строк датасета
data.head()
```

Out[6]:

| | Unnamed: 0 | id | Name | RawgID | SteamURL | Metacritic | Genres | Indie | Presence |
|---|---|---|---|---|---|---|---|---|---|
| 0 | 0 | 1 | Counter-Strike: Global Offensive | 4291.0 | https://store.steampowered.com/app/730/?snr=1_... | 83.0 | Action, Free to Play | 0.0 | 1009588.0 |
| 1 | 1 | 2 | Destiny 2 | 32.0 | https://store.steampowered.com/app/1085660/?sn... | 82.0 | Action, Adventure, Free to Play | 0.0 | 1007425.0 |
| 2 | 2 | 3 | Dota 2 | 10213.0 | https://store.steampowered.com/app/570/?snr=1_... | 90.0 | NaN | 0.0 | 1009306.0 |
| 3 | 3 | 4 | The Elder Scrolls Online | 41458.0 | https://store.steampowered.com/app/306130/?snr... | 71.0 | Massively Multiplayer, RPG | 0.0 | 1000781.0 |

| | Unnamed: 0 | id | Name | RawgID | SteamURL | Metacritic | Genres | Indie | Presence |
|---|---|---|---|---|---|---|---|---|---|
| 4 | 4 | 5 | Sea of Thieves | 50781.0 | https://store.steampowered.com/app/1172620/? | 68.0 | Action, Adventure | 0.0 | 777456.0 |

**5 rows × 27 columns**

In [7]:

```
total_count = data.shape[0]
print('Всего строк: {}'.format(total_count))
```

```
Всего строк: 30250
```

# Обработка пропусков в данных

## Простые стратегии - удаление или заполнение нулями

In [8]:

```
# Удаление колонок, содержащих пустые значения
data_new_1 = data.dropna(axis=1, how='any')
(data.shape, data_new_1.shape)
```

Out[8]:

```
((30250, 27), (30250, 2))
```

Удаление колонок, содержащих пустые значения приведет к сокращению колонок с **27** до **2**

In [9]:

```
# Удаление строк, содержащих пустые значения
data_new_2 = data.dropna(axis=0, how='any')
(data.shape, data_new_2.shape)
```

Out[9]:

```
((30250, 27), (0, 27))
```

Удаление строк, содержащих пустые значения приведет к сокращению строк с **30250** до **0**

In [10]:

```
# Удаление колонки Publisher и Unnamed: 0 из-за неиспользования  в данной работе связей
с другими датасетами
data = data.drop('Publisher', 1)
data = data.drop('Unnamed: 0', 1)
data.shape
```

Out[10]:

```
(30250, 25)
```

In [11]:

```
# Удаление строк, имеющих пустые значения в колонке Name
data = data.dropna(axis=0, subset=['Name'])
data.shape
```

Out[11]:

```
(30156, 25)
```

In [12]:

```
data.head()
```

Out[12]:

| | id | Name | RawgID | SteamURL | Metacritic | Genres | Indie | Presence | Platform |
|---|---|---|---|---|---|---|---|---|---|
| 0 | 1 | Counter-Strike: Global Offensive | 4291.0 | https://store.steampowered.com/app/730/?snr=1_... | 83.0 | Action, Free to Play | 0.0 | 1009588.0 | PC, Xbox 360, PlayStation 3 |
| 1 | 2 | Destiny 2 | 32.0 | https://store.steampowered.com/app/1085660/?sn... | 82.0 | Action, Adventure, Free to Play | 0.0 | 1007425.0 | PlayStation 5, Web, Xbox Series X, PC, Xbox On... |
| 2 | 3 | Dota 2 | 10213.0 | https://store.steampowered.com/app/570/?snr=1_... | 90.0 | NaN | 0.0 | 1009306.0 | Linux, macOS, PC |
| 3 | 4 | The Elder Scrolls Online | 41458.0 | https://store.steampowered.com/app/306130/?snr... | 71.0 | Massively Multiplayer, RPG | 0.0 | 1000781.0 | PC |
| 4 | 5 | Sea of Thieves | 50781.0 | https://store.steampowered.com/app/1172620/?sn... | 68.0 | Action, Adventure | 0.0 | 777456.0 | PC, Xbox One |

5 rows × 25 columns

In [13]:

```
# Заполнение всех пропущенных значений нулями
# В данном случае это некорректно, так как нулями заполняются в том числе категориальные колонки
data_new_3 = data.fillna(0)
data_new_3.head()
```

Out[13]:

| | id | Name | RawgID | SteamURL | Metacritic | Genres | Indie | Presence | Platform |
|---|---|---|---|---|---|---|---|---|---|
| 0 | 1 | Counter-Strike: Global Offensive | 4291.0 | https://store.steampowered.com/app/730/?snr=1_... | 83.0 | Action, Free to Play | 0.0 | 1009588.0 | PC, Xbox 360, PlayStation 3 |
| 1 | 2 | Destiny 2 | 32.0 | https://store.steampowered.com/app/1085660/?sn... | 82.0 | Action, Adventure, Free to Play | 0.0 | 1007425.0 | PlayStation 5, Web, Xbox Series X, PC, Xbox On... |
| 2 | 3 | Dota 2 | 10213.0 | https://store.steampowered.com/app/570/?snr=1_... | 90.0 | 0 | 0.0 | 1009306.0 | Linux, macOS, PC |
| 3 | 4 | The Elder Scrolls | 41458.0 | https://store.steampowered.com/app/306130/?snr... | 71.0 | Massively Multiplayer, RPG | 0.0 | 1000781.0 | PC |

| | id | Online Name | RawgID | SteamURL | Metacritic | Genres | Indie | Presence | Platform |
|---|---|---|---|---|---|---|---|---|---|
| 4 | 5 | Sea of Thieves | 50781.0 | https://store.steampowered.com/app/1172620/?sn... | 68.0 | Action, Adventure | 0.0 | 777456.0 | PC, Xbox One |

5 rows × 25 columns

# "Внедрение значений" - импьютация **(imputation)**

## Обработка пропусков в числовых данных

In [14]:

```
# Выберем числовые колонки с пропущенными значениями
# Цикл по колонкам датасета
num_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='float64' or dt=='int64'):
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(co
l, dt, temp_null_count, temp_perc))
```

```
Колонка Metacritic. Тип данных float64. Количество пустых значений 26800, 88.6%.
Колонка Indie. Тип данных float64. Количество пустых значений 205, 0.68%.
Колонка Soundtrack. Тип данных float64. Количество пустых значений 205, 0.68%.
Колонка Controller. Тип данных float64. Количество пустых значений 274, 0.91%.
```

In [15]:

```
# Фильтр по колонкам с пропущенными значениями
data_num = data[num_cols]
data_num
```

Out[15]:

| | Metacritic | Indie | Soundtrack | Controller |
|---|---|---|---|---|
| 0 | 83.0 | 0.0 | 0.0 | 1.0 |
| 1 | 82.0 | 0.0 | 0.0 | 1.0 |
| 2 | 90.0 | 0.0 | 0.0 | 1.0 |
| 3 | 71.0 | 0.0 | 0.0 | 1.0 |
| 4 | 68.0 | 0.0 | 0.0 | 1.0 |
| ... | ... | ... | ... | ... |
| 30245 | NaN | 1.0 | 0.0 | 1.0 |
| 30246 | NaN | 1.0 | 0.0 | 0.0 |
| 30247 | NaN | 0.0 | 0.0 | 0.0 |
| 30248 | NaN | 1.0 | 0.0 | 1.0 |
| 30249 | NaN | 0.0 | 0.0 | 1.0 |

30156 rows × 4 columns

In [16]:

```
# Определим уникальные значения для полей
```

```
(data['Soundtrack'].unique(),
 data['Controller'].unique(),
 data['Indie'].unique())
```

Out[16]:

```
(array([ 0.,  1., nan]), array([ 1.,  0., nan]), array([ 0.,  1., nan]))
```

In [17]:

```
# Гистограмма по признакам
for col in data_num:
    plt.hist(data[col], 50)
    plt.xlabel(col)
    plt.show()
```

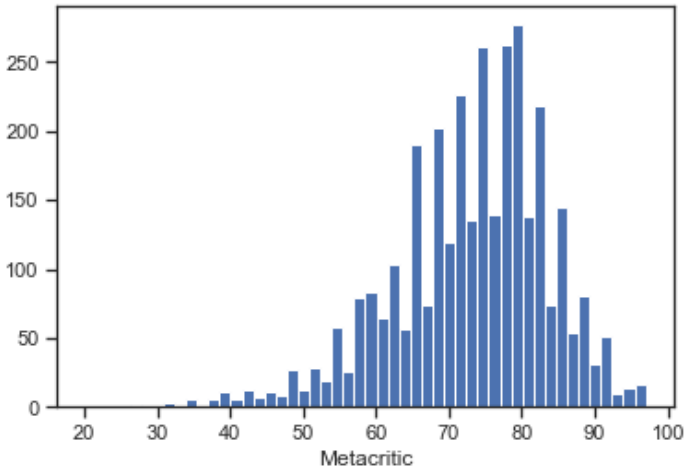


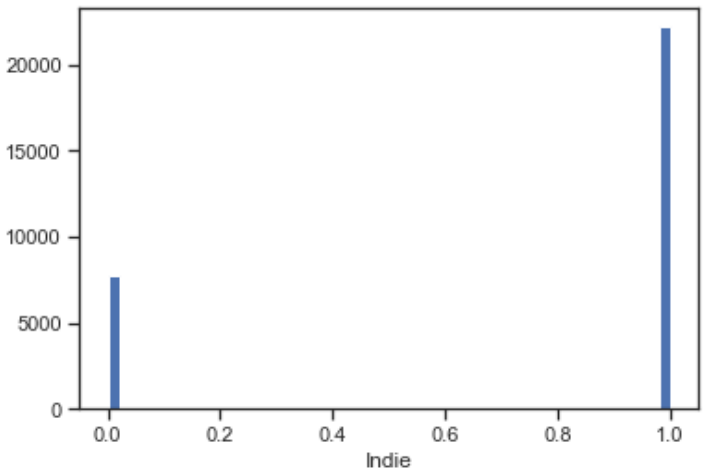


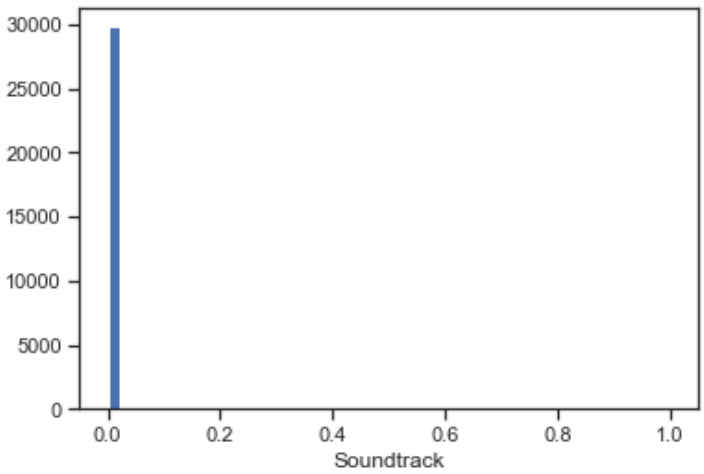


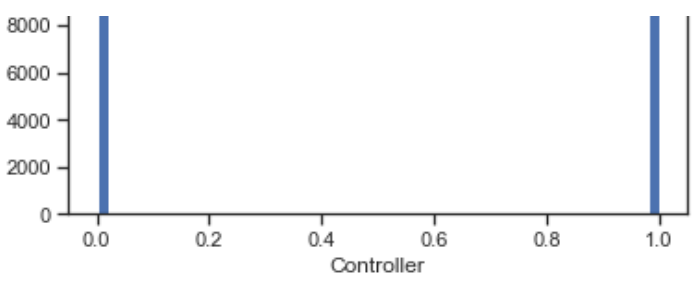


In [18]:

```
data_num_Metacritic = data_num[['Metacritic']]
data_num_Metacritic.head()
```

Out[18]:

| | Metacritic |
|---|---|
| **0** | **83.0** |
| **1** | **82.0** |
| **2** | **90.0** |
| **3** | **71.0** |
| **4** | **68.0** |

In [19]:

```
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator
```

In [20]:

```
# Фильтр для проверки заполнения пустых значений
indicator = MissingIndicator()
mask_missing_values_only = indicator.fit_transform(data_num_Metacritic)
mask_missing_values_only
```

Out[20]:

```
array([[False],
       [False],
       [False],
       ...,
       [ True],
       [ True],
       [ True]])
```

Попробуем заполнить пропущенные значения в колонке **Metacritics** значениями, вычисленными по среднему арифметическому, медиане и моде.

In [21]:

```
strategies=['mean', 'median', 'most_frequent']
```

In [22]:

```
def test_num_impute(strategy_param):
    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(data_num_Metacritic)
    return data_num_imp[mask_missing_values_only]
```

In [23]:

```
strategies[0], test_num_impute(strategies[0])
```

Out[23]:

```
('mean',
 array([72.92491061, 72.92491061, 72.92491061,        72.92491061
```

```
       72.92491061, 72.92491061]))
```

In [24]:

```
strategies[1], test_num_impute(strategies[1])
```

Out[24]:

```
('median', array([74., 74., 74., ..., 74., 74., 74.]))
```

In [25]:

```
strategies[2], test_num_impute(strategies[2])
```

Out[25]:

```
('most_frequent', array([80., 80., 80., ..., 80., 80., 80.]))
```

In [26]:

```
# Более сложная функция, которая позволяет задавать колонку и вид импьютации
def test_num_impute_col(dataset, column, strategy_param):
    temp_data = dataset[[column]]

    indicator = MissingIndicator()
    mask_missing_values_only = indicator.fit_transform(temp_data)

    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(temp_data)

    filled_data = data_num_imp[mask_missing_values_only]

    return column, strategy_param, filled_data.size, filled_data[0], filled_data[filled_
data.size-1]
```

In [28]:

```
data[['Metacritic']].describe()
```

Out[28]:

| | Metacritic |
|---|---|
| count | 3356.000000 |
| mean | 72.924911 |
| std | 10.805296 |
| min | 20.000000 |
| 25% | 67.000000 |
| 50% | 74.000000 |
| 75% | 80.000000 |
| max | 97.000000 |

In [29]:

```
test_num_impute_col(data, 'Metacritic', strategies[0])
```

Out[29]:

```
('Metacritic', 'mean', 26800, 72.92491060786651, 72.92491060786651)
```

In [30]:

```
test_num_impute_col(data, 'Metacritic', strategies[1])
```

Out[30]:

```
('Metacritic', 'median', 26800, 74.0, 74.0)
```

In [31]:

```
test_num_impute_col(data, 'Metacritic', strategies[2])
```

Out[31]:

```
('Metacritic', 'most_frequent', 26800, 80.0, 80.0)
```

## Обработка пропусков в категориальных данных

In [33]:

```
# Выберем категориальные колонки с пропущенными значениями
# Цикл по колонкам датасета
cat_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='object'):
        cat_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(co
l, dt, temp_null_count, temp_perc))
```

```
Колонка SteamURL. Тип данных object. Количество пустых значений 55, 0.18%.
Колонка Genres. Тип данных object. Количество пустых значений 2962, 9.79%.
Колонка Platform. Тип данных object. Количество пустых значений 33, 0.11%.
Колонка Graphics. Тип данных object. Количество пустых значений 4305, 14.23%.
Колонка Storage. Тип данных object. Количество пустых значений 2752, 9.1%.
Колонка Memory. Тип данных object. Количество пустых значений 1927, 6.37%.
Колонка RatingsBreakdown. Тип данных object. Количество пустых значений 15112, 49.96%.
Колонка ReleaseDate. Тип данных object. Количество пустых значений 3132, 10.35%.
Колонка Franchise. Тип данных object. Количество пустых значений 25079, 82.91%.
Колонка OriginalCost. Тип данных object. Количество пустых значений 743, 2.46%.
Колонка DiscountedCost. Тип данных object. Количество пустых значений 29429, 97.29%.
Колонка Players. Тип данных object. Количество пустых значений 17868, 59.07%.
Колонка Languages. Тип данных object. Количество пустых значений 223, 0.74%.
Колонка ESRB. Тип данных object. Количество пустых значений 25409, 84.0%.
Колонка Description. Тип данных object. Количество пустых значений 125, 0.41%.
Колонка Tags. Тип данных object. Количество пустых значений 205, 0.68%.
```

- Колонки, содержащие менее **5%** пропусков выбираем для построения модели.
- Колонки, содержащие менее **30%** пропусков также выбираем для построения модели.
- Колонки **RatingsBreakdown (49.96%)** и **Players (59.07%)** не выбираем для построения модели, в случае отсутствия необходимости в этих колонках.
- Колонки **Franchise (82.91%), DiscountedCost (97.29%)** и **ESRB (84.0%)** не выбираем для построения модели в любом случае.

In [34]:

```
cat_temp_data = data[['Genres']]
cat_temp_data.head()
```

Out[34]:

| | Genres |
|---|---|
| 0 | Action, Free to Play |
| 1 | Action, Adventure, Free to Play |
| 2 | NaN |
| 3 | Massively Multiplayer, RPG |
| 4 | Action, Adventure |

In [35]:

```
cat_temp_data['Genres'].unique()
```

Out[35]:

```
array(['Action, Free to Play', 'Action, Adventure, Free to Play', nan,
       ..., 'Casual, Indie, Massively Multiplayer, RPG, Early Access',
       'Action, Adventure, Casual, Racing, Simulation, Strategy',
       'Action, Adventure, Casual, Sports, Strategy'], dtype=object)
```

In [36]:

```
cat_temp_data[cat_temp_data['Genres'].isnull()].shape
```

Out[36]:

```
(2962, 1)
```

In [37]:

```
# Импьютация наиболее частыми значениями
imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
data_imp2 = imp2.fit_transform(cat_temp_data)
data_imp2
```

Out[37]:

```
array([['Action, Free to Play'],
       ['Action, Adventure, Free to Play'],
       ['Action, Indie'],
       ...,
       ['Casual'],
       ['Action, Adventure, Casual, Indie'],
       ['Action, Indie']], dtype=object)
```

In [38]:

```
# Пустые значения отсутствуют
np.unique(data_imp2)
```

Out[38]:

```
array(['Action', 'Action, Adventure', 'Action, Adventure, Casual', ...,
       'Strategy, Indie, Casual, Simulation', 'Strategy, RPG, Indie',
       'Strategy, Simulation'], dtype=object)
```

In [39]:

```
# Импьютация константой
imp3 = SimpleImputer(missing_values=np.nan, strategy='constant', fill_value='NA')
data_imp3 = imp3.fit_transform(cat_temp_data)
data_imp3
```

Out[39]:

```
array([['Action, Free to Play'],
       ['Action, Adventure, Free to Play'],
       ['NA'],
       ...,
       ['Casual'],
       ['Action, Adventure, Casual, Indie'],
       ['NA']], dtype=object)
```

In [40]:

```
np.unique(data_imp3)
```

Out[40]:

```
array(['Action', 'Action, Adventure', 'Action, Adventure, Casual', ...,
       'Strategy, Indie, Casual, Simulation', 'Strategy, RPG, Indie',
       'Strategy, Simulation'], dtype=object)
```

In [41]:

```
data_imp3[data_imp3=='NA'].size
```

Out[41]:

```
2962
```

Таким образом, в колонку **Genres** вставлено **2962 "NA",** вместо пропущенных значений.

# Преобразование категориальных признаков в числовые

In [42]:

```
cat_enc = pd.DataFrame({'c1':data_imp2.T[0]})
cat_enc
```

Out[42]:

| | c1 |
|---|---|
| **0** | **Action, Free to Play** |
| **1** | **Action, Adventure, Free to Play** |
| **2** | **Action, Indie** |
| **3** | **Massively Multiplayer, RPG** |
| **4** | **Action, Adventure** |
| **...** | **...** |
| **30151** | **Casual, Indie** |
| **30152** | **Indie** |
| **30153** | **Casual** |
| **30154** | **Action, Adventure, Casual, Indie** |
| **30155** | **Action, Indie** |

**30156 rows × 1 columns**

## Кодирование категорий целочисленными значениями - label encoding

In [43]:

```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

In [44]:

```
le = LabelEncoder()
cat_enc_le = le.fit_transform(cat_enc['c1'])
```

In [45]:

```
cat_enc['c1'].unique()
```

Out[45]:

```
array(['Action, Free to Play', 'Action, Adventure, Free to Play',
       'Action, Indie', ...,
       'Casual, Indie, Massively Multiplayer, RPG, Early Access',
       'Action, Adventure, Casual, Racing, Simulation, Strategy',
       'Action, Adventure, Casual, Sports, Strategy'], dtype=object)
```

In [46]:

```
np.unique(cat_enc_le)
```

Out[46]:

```
array([   0,    1,    2, ..., 1003, 1004, 1005])
```

## Кодирование категорий наборами бинарных значений - one-hot encoding

In [47]:

```
ohe = OneHotEncoder()
cat_enc_ohe = ohe.fit_transform(cat_enc[['c1']])
```

In [48]:

```
cat_enc.shape
```

Out[48]:

```
(30156, 1)
```

In [49]:

```
cat_enc_ohe.shape
```

Out[49]:

```
(30156, 1006)
```

In [50]:

```
cat_enc_ohe
```

Out[50]:

```
<30156x1006 sparse matrix of type '<class 'numpy.float64'>'
 with 30156 stored elements in Compressed Sparse Row format>
```

In [51]:

```
cat_enc_ohe.todense()[0:10]
```

Out[51]:

```
matrix([[0., 0., 0., ..., 0., 0., 0.],
        [0., 0., 0., ..., 0., 0., 0.],
        [0., 0., 0., ..., 0., 0., 0.],
        ...,
        [0., 0., 0., ..., 0., 0., 0.],
        [1., 0., 0., ..., 0., 0., 0.],
        [0., 0., 0., ..., 0., 0., 0.]])
```

In [52]:

```
cat_enc.head(10)
```

Out[52]:

| | c1 |
|---|---|
| 0 | Action, Free to Play |
| 1 | Action, Adventure, Free to Play |
| 2 | Action, Indie |
| 3 | Massively Multiplayer, RPG |
| 4 | Action, Adventure |
| 5 | Adventure, Indie, Simulation, Strategy, Early ... |
| 6 | Action |
| 7 | Action, Indie, Racing, Sports |

| | |
|---|---|
| 8 | Action<br>c1 |
| 9 | Action, Adventure, Indie, Massively Multiplaye... |

## Pandas get_dummies - быстрый вариант **one-hot** кодирования

In [53]:

```
pd.get_dummies(cat_enc).head()
```

Out[53]:

| | c1_Action | c1_Action, Adventure | c1_Action, Adventure, Casual | c1_Action, Adventure, Casual, Early Access | c1_Action, Adventure, Casual, Free to Play, Indie | c1_Action, Adventure, Casual, Free to Play, Indie, Early Access | c1_Action, Adventure, Casual, Free to Play, Indie, Massively Multiplayer | c1_Action, Adventure, Casual, Free to Play, Indie, Massively Multiplayer, RPG | c1_Action, Adventure, Casual, Free to Play, Indie, Massively Multiplayer, RPG, Early Access | c1_Action, Adventure, Casual, Free to Play, Indie, Massively Multiplayer, RPG, Simulation | .. |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | .. |
| 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | .. |
| 2 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | .. |
| 3 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | .. |
| 4 | 0 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | .. |

5 rows × 1006 columns

In [54]:

```
pd.get_dummies(cat_temp_data, dummy_na=True).head()
```

Out[54]:

| | Genres_Action | Genres_Action, Adventure | Genres_Action, Adventure, Casual | Genres_Action, Adventure, Casual, Early Access | Genres_Action, Adventure, Casual, Free to Play, Indie | Genres_Action, Adventure, Casual, Free to Play, Indie, Early Access | Genres_Action, Adventure, Casual, Free to Play, Indie, Massively Multiplayer | Genres_Ac Adven Casual, Fr Play, I Mass Multipl |
|---|---|---|---|---|---|---|---|---|
| 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | |
| 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | |
| 2 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | |
| 3 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | |
| 4 | 0 | 1 | 0 | 0 | 0 | 0 | 0 | |

5 rows × 1007 columns

# Масштабирование данных

- **MinMax** масштабирование:

$$x_{\text{новый}} \\ x_{\text{старый}} \\ \_ - min(X)$$

$$- \frac{}{max(X) - min(X)}$$

В этом случае значения лежат в диапазоне от **0** до **1.**

- Масштабирование данных на основе [Z-оценки]:

$$x_{новый} \\ x_{старый} \\ = \frac{- AVG(X)}{\sigma(X)}$$

В этом случае большинство значений попадает в диапазон от **-3** до **3.**

где $X$ - матрица объект-признак, $AVG(X)$ - среднее значение, $\sigma$ - среднеквадратичное отклонение.

In [55]:

```
from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
```

## MinMax масштабирование

In [56]:

```
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['Metacritic']])
```

In [57]:

```
plt.hist(data['Metacritic'], 50)
plt.show()
```

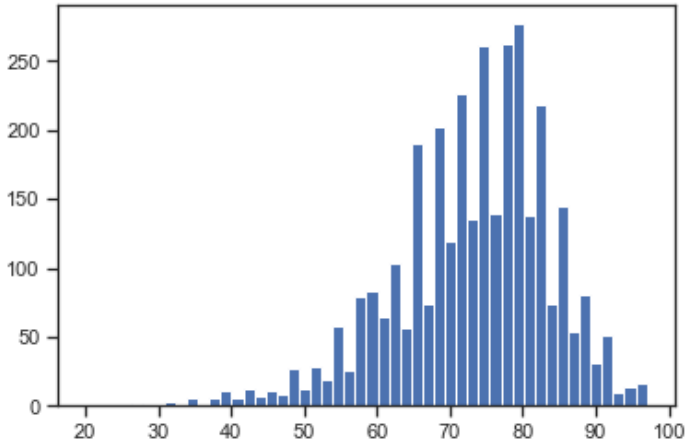


In [58]:

```
plt.hist(sc1_data, 50)
plt.show()
```

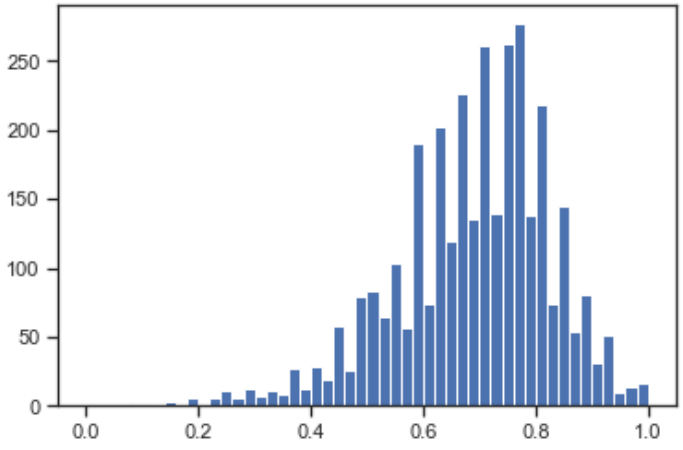

## Масштабирование данных на основе Z-оценки - StandardScaler

In [59]:

```
sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data[['Metacritic']])
```

In [60]:

```
plt.hist(sc2_data, 50)
plt.show()
```